


产生式系统的搜索

**状态空间法(S,F,G)**(初始状态 操作符 目标状态)  
如食人生番:动作 op(b1,b2,b3)(人数,野人数,哪岸到哪岸)  
状态(a1,a2,a3)(左岸人 num,左岸野人 num,船在左 or 右)  
状态转换:  $A \rightarrow B$ , *OPERATOR*(操作对象,初值,终值)  
**搜索**:宽/深:后代放进 open-后代是否目标-取点放进 closed  
**等费用搜索**:  $g(n_{i+1}) = g(n_i) + c(n_i, n_{i+1})$  每次从 open 表中选  $g$  最小的节点, 判断该点是否为目标, 然后放进 closed 表  
**爬山法**:  $h(n)$  表示到目标点最短路费用。open 表找点-判断-放进 closed-循环。  
**A 算法**:初始 S/当前 n/目标(ti)。  $h^*(n) = \min\{k(n,t_i)\}$  n 到 ti 最小代价,  $g^*(n) = k(S,n)$  S-n 最小代价。  $f^*(n) = g^*(n) + h^*(n)$   
找 f 最小点-放-判断-扩展(如果有则判断新旧 f 的大小)  
**A\*算法**:用  $h(n) \leq h^*(n)$  和  $g(n) \geq g^*(n)$  作为  $h^*(n)$   $g^*(n)$  估计。  
/完备性:有解一定能找到/可采纳(宽/等/A\*):若存在代价最小解一定能找到/最优性:可采纳  $A_1A_2, h_1 < h_2$ , 结束时  $A_1$  展开的节点至少和  $A_2$  一样多。(h 越小越保守展开的节点越多)  
/深度优先:  $h(n) = 0, g(n) = d(n)$  /等费  $h(n) = 0, f(n) = g(n) + 0$   
/宽度优先:  $h(n)$  足够大,  $g(n) = 0, f(n) = h(n)$   
**计算复杂性**  $f(x) = O(g(x)) \Rightarrow \exists A, B > 0, A \leq |f/g| \leq B$   
**NP 类问题**:有多项式时间算法解决的判定问题(有  $P \subseteq NP$ )  
**NP 类问题**:对猜想存在多项式时间算法来验证的判定问题  
 $A \propto B$ :问题 A 对问题 B 是多项式可简化的  $\rightarrow A$  调用 B, B 程序作为一个步骤, A 的算法是多项式时间算法。  
 $a.P_B \in P, P_A \propto P_B \Rightarrow P_A \in P$  ( $P_B$  解决  $\rightarrow P_A$  解决)  
 $b.P_B \in NP, P_A \propto P_B \Rightarrow P_B$  至少和  $P_A$  一样难  
**NP 完全问题**: (NP 中最难的问题)判定问题  $P_1 \in NP$ , 对所有其他判定问题  $P_m \in NP$ , 有  $P_m \propto P_1$ , 则  $P_1$  是 NP 完全的。  
**定理**:  $P_1, P_2 \in NP, P_1$  是 NP 完全,  $P_1 \propto P_2$ , 则  $P_2$  是 NP 完全的。  
所有 NP 构成集合彼此等价, 解决一个解决所有。  
**NP 难题**:  $P_1 \propto P_2, P_1 \in NP$  完全  $\Rightarrow P_2$  是 NP 难的。  $P_2$  至少和  $P_1$  一样难。如 TSP 问题不是判定问题, 但它是 NP 难题。  
**问题归约和与或图搜索**:大问题拆为小问题/画树  
问题规约:根节点是起始问题, 叶节点是本原问题。  
**与或图**:注意弧线! 有弧线是与, 没弧线是或。  
叶节点一定可解;非叶节点:若有或(与)后继点, 那么至少一个(全部)后继可解时, 该非叶节点可解。  
非叶节点无后继不可解/或(与)后继全不(有一个)可解。  
**深/宽搜**:找到可解点即回溯, 可解移进 closed/不可解删除。  
**AO\***:当  $h(n) \leq h^*(n)$  且  $h(n)$  满足单调限制条件时, AO\* 算法具有可采纳性.先扩展代价小的解图(相同时优先当前)  
**博弈树搜索**:与或图, 我方或, 对方与  
**极大极小搜索**:我方取后继的 MAX, 对方取后继的 MIN。  
 $\alpha - \beta$  剪枝:用深搜。  $\alpha$  是 MAX 的下界;  $\beta$  是 MIN 的上界。  
 $\alpha$ :  $\beta$  (后继层)  $\leq \alpha$  (先辈层), 中值该 MIN 层后续搜索;  
 $\beta$ :  $\alpha$  (后继层)  $\geq \beta$  (先辈层), 中值该 MAX 层后续搜索。  
效率:设深度为  $P$ , 每个节点有  $B$  个后继, 生成端节点最小值  $N_p$ 。  $p$  为偶数:  $N_p = 2B^{P/2} - 1$ ;  $p$  为奇数:  $N_p = B^{(P+1)/2} + B^{(P-1)/2} - 1$   
**蒙特卡洛树搜索**:权重  $I_j = \bar{v}_j + c \sqrt{\ln N / n_j}$  ( $N$  是总访问次数)  
 $n_j, \bar{v}_j$  算法开始到现在, 节点  $j$  被访问的次数和平均收益  
流程:选择-拓展-模拟-反向传播

**谓词逻辑与归结原理**:命题是具有唯一真值的陈述句。  
2.  $\wedge$ :合取(与)  $\vee$ :析取(或)  $\rightarrow$ :蕴含  $\leftrightarrow$ :等价  
3.  $p \rightarrow q$  为假当且仅当  $p = T, q = F$   
4. 永真/重言式:永假/矛盾式:假; 可满足式:至少一个成真赋值; **非重言式的可满足式**:至少一个成真一个成假  
5. 吸收律:  $A \vee (A \wedge B) \Leftrightarrow A, A \wedge (A \vee B) \Leftrightarrow A$   
 $A \vee (B \wedge C) \Leftrightarrow (A \vee B) \wedge (A \vee C)$   
 $A \wedge (B \vee C) \Leftrightarrow (A \wedge B) \vee (A \wedge C)$   
 $\sim (A \vee B) = \sim B \wedge \sim A, \sim (A \wedge B) = B \vee \sim A$   
**重要**:  $A \rightarrow B \Leftrightarrow \sim A \vee B, (A \rightarrow B) \wedge (A \rightarrow \sim B) \Leftrightarrow \sim A$   
 $A \rightarrow B \Leftrightarrow (A \rightarrow B) \wedge (A \rightarrow A)$   
 $A \rightarrow B \Leftrightarrow \sim B \rightarrow \sim A, A \leftrightarrow B \Leftrightarrow A \leftrightarrow \sim \sim B$   
6. 原子公式:不含任何联结词的公式//子句:任何文字的析取式; 文字:原子或~原子//合取**范式**:简单析取式构成的合取式//析取范式:简单合取式构成的析取式  
**命题逻辑的推理规则**  
7. 附加:  $A \Rightarrow (A \vee B)$ ; 假言推理:  $((A \rightarrow B) \wedge A) \Rightarrow B$   
简化:  $(A \wedge B) \Rightarrow A$ ; 拒取式:  $((A \rightarrow B) \wedge \sim B) \Rightarrow \sim A$   
析取三段论:  $((A \vee B) \wedge \sim A) \Rightarrow B$   
假言三段论:  $((A \rightarrow B) \wedge (B \rightarrow C)) \Rightarrow (A \rightarrow C)$   
等价三段论:  $((A \leftrightarrow B) \wedge (B \leftrightarrow C)) \Rightarrow (A \leftrightarrow C)$   
构造性二难:  $(A \rightarrow B) \vee (C \rightarrow D) \wedge (A \vee C) \Rightarrow (B \vee D)$   
可做:前提引入/结论引入/置换规则比如  $\sim p \vee q$  换  $p \rightarrow q$   
**命题逻辑的归结方法**  
8. 子句:简单析取式, 项是一个变量或其否定。  
子句集:合取范式中所有子句的集合, A 换成 “, ”。  
9. 归结原理:如  $p \vee q$  和  $\sim p \vee r$  都为真, 那么  $p \vee r$  为真。  
10. 归结式:  $C_1 = P \vee C'_1, C_2 = \sim P \vee C'_2$  归结  $C_{12} = C'_1 \vee C'_2$   
11. 归结 (消解) 法:为了证明  $A \rightarrow B$  真, 先转为  $A \wedge \sim B$ , 证明

该命题公式永假。提取其子句集, 归结为空即可。  
**谓词逻辑** 12. 个体词/谓词 任意/存在量词 约束出现/自由出现//函数是个体域到个体域的映射, 不同于谓词  
13. 换名:辖域中约束出现的变量名换掉/替代:自由出现的个体变量名字可换掉 14. 谓词公式永真称为逻辑有效/永真的, 谓词公式永假称为不一致/不可满足。  
15. **谓词演算公式**  $(\forall x)P(x) \Leftrightarrow (\exists y) \sim P(y)$   
 $\sim (\exists x)P(x) \Leftrightarrow (\forall y) \sim P(y)$   
 $(\forall x)(P(x) \wedge Q(x)) \Leftrightarrow (\forall x)P(x) \wedge (\forall x)Q(x)$   
 $(\exists x)(P(x) \vee Q(x)) \Leftrightarrow (\exists x)P(x) \vee (\exists x)Q(x)$   
 $(\forall x)(P(x) \rightarrow Q) \Leftrightarrow (\exists x)P(x) \rightarrow Q$   
 $(\forall x)(Q \rightarrow P(x)) \Leftrightarrow Q \rightarrow (\forall x)P(x)$   
 $(\exists x)(P(x) \rightarrow Q) \Leftrightarrow (\forall x)P(x) \rightarrow Q$   
 $(\exists x)(Q \rightarrow P(x)) \Leftrightarrow Q \rightarrow (\exists x)P(x)$   
注意:  $(\exists x)(P(x) \wedge Q(x)) \neq (\exists x)P(x) \wedge (\exists x)Q(x)$   
 $(\forall x)(P(x) \vee Q(x)) \neq (\forall x)P(x) \wedge (\exists x)Q(x)$   
16. **前束范式**:将量词均提到最左边  
17. 谓词推理:存在用常量替代, 任意用变量 or 常量替代  
**谓词逻辑归结原理**  
18. skolem 标准型:变前束范式; 消去存在量词; 略去全称量词例子:  $\forall x \exists y P(x, y) \rightarrow \forall x P(x, f(x)) \quad \exists x f(x) \rightarrow f(c)$   
19. **置换**:  $\theta = \{t_1/a_1, \dots\}$ , 用  $t_i$  代替  $a_i$   
结合律  $(\theta \cdot \lambda_1) \lambda_2 = \theta (\lambda_1 \cdot \lambda_2)$ , 不满足交换律。  
20. 合一:  $F = \{F_1, F_2, \dots\}$ , 存在置换  $\theta$ , 使  $F \theta = F_2 \theta \dots$ 。  
21. **最一般合一**  $\theta$  是  $F$  的最一般置换, 换  $F$  的任一合一  $\theta$ , 都有置换  $\lambda$ , 有  $\theta = \alpha \lambda$  (从左比较对应项不同就换)  
22. **归结过程**:反演-化 skolem-求子句集-归结-空子句。  
23. 宽优先:可删永真式/重复出现/被归类子句(当且仅当  $\exists \lambda, C \lambda, C, D$  被归类, 比如  $C = P(x), D = P(a) \vee Q(y)$ )  
24. 支持集优:归结子句至少 1 个与目标公式否定有关  
25. 单元子句优先:优先选择单元文字归结(不完备)  
**基于规则的推理** 25. 事实表达式的与或树  
26. 正向演绎系统:化为 skolem 范式,  $\wedge$ 或  $\vee$ 与。每个子句是解图叶节点析取;  $L \rightarrow W$ 。  
 $X \wedge Y \rightarrow Z$  化成  $X \rightarrow \sim Y \vee Z$  或  $Y \rightarrow \sim X \vee Z$   
 $X \vee Y \rightarrow Z$  化成  $X \rightarrow Z$  且  $Y \rightarrow Z$   
推理过程图:目标在上, 事实在下。  
  
27. 逆向演绎系统:  $W \rightarrow L$  (这是结论推条件),  $\vee$ 或  $\wedge$ 与。  
 $Z \rightarrow X \wedge Y$  化成  $Z \rightarrow X$  且  $Z \rightarrow Y$   
 $Z \rightarrow X \vee Y$  化成  $Z \wedge \sim X \rightarrow Y$  或  $Z \wedge \sim Y \rightarrow X$   
根:待证明结论, 叶:事实, 反向利用规则。  
CAT(x)  $\wedge$  DOG(y)  $\wedge$  7AFRAID(x,y) 这是目标  
CAT(x)  $\wedge$  (x5/x5) DOG(y)  $\wedge$  (pluto/y)  $\wedge$  (y2/x, x2/y)  
CAT(x5) DOG (pluto) 7AFRAID(y2,x2)  
MEOWS(x5) 7BARKS(x2) FRIENDLY(x2)  
Kitty/x5 (Kitty/x2) (pluto/x2)  $\wedge$  (x1/x2)  
MEOWS(Kitty) 7BARKS(Pluto) FRIENDLY(x1)  
红字是事实, 推理规则  $W \rightarrow L$   
根据规则, 先知道箭头右边, 然后推出箭头左边。  
WAGS-TAIL(x1) DOG(x1)  
WAGS-TAIL(Pluto) DOG(pluto)

**基于规则的系统(产生式系统)**  
28. 构成:控制策略/产生式规则/总数据库  
29. 总数据库:存初始状态/事实/证据/中间和最后结果  
30. 规则库:存放与求解问题有关领域的知识  
完整(任何情况有可用)-一致(不能互相矛盾)/准确性  
31. 控制策略:是推理结构。从规则库中选择规则的策略, 把中间结论放入总数据库, 解决问题。  
**知识表示** 分类:事务性/事件性/性能性/元知识  
1. 事实的表示:(对象, 属性, 值)(关系, 对象 1, 对象 2)(对象属性, 值, 不确定度); 规则的表示:  $\rightarrow$   
**语义网络**:节点—关系—节点  
4. Is-a:具体与抽象(继承属性); Part-of:部分和整体, 无继承; 是一个节点是另一个节点的性质  
5. 属性 (类属) 关系:Have/a-kind-of/can  
6. 其他关系:Before/after(时间关系)similar-to/near-to(相似关系)locate-on/at/under.inside/outside(位置关系)  
Event 型:agent(施动者), Object(受动者)  
**语义网络的推理**  
7. 继承:isA ako 预测:If-needed:利用已知信息计算 (weight) Default 缺省:对事物不很有把握 pku-good?  
8. 知识图谱:本质是语义网络(head, relation, tail)  
节点是实体或概念, 边代表关系。wordnet/frebase

监督学习:线性回归

**线性回归**:  $y = ax + b$  找函数族/找优化准则/找最优函数  
 $S_{xx} = \sum (x_i - \bar{x})^2, S_{yy} = \sum (x_i - \bar{x})(y_i - \bar{y}), S_{yy} = \sum (y_i - \bar{y})^2$   
**最小二乘**:  $\hat{\omega} = \frac{S_{xy}}{S_{xx}} = \frac{\sum x_i y_i - n \bar{x} \bar{y}}{\sum x_i^2 - n \bar{x}^2} = \frac{S_{xy}}{S_{xx}}, \hat{b} = \bar{y} - \hat{\omega} \bar{x} = \bar{Y} - \hat{\omega} \bar{X}$

**最大似然估计**:  $Y_i = ax_i + b + \varepsilon_i, Y_i | x_i \sim N(ax_i + b, \sigma^2)$

概率密度函数:  $f(y_i | \omega, b, x_i) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{[y_i - (ax_i + b)]^2}{2\sigma^2}\right\}$

$l = \log L = \log \prod_{i=1}^n f = -\frac{n \log(2\pi)}{2} - n \log(\sigma) - \frac{1}{2\sigma^2} \sum_{i=1}^n [y_i - (ax_i + b)]^2$

去找使似然函数值  $l$  最大的参数值, 结果同最小二乘法。

参数  $\hat{\omega} = \frac{S_{xy}}{S_{xx}} = \sum \frac{x_i - \bar{x}}{S_{xx}} Y_i, \hat{\omega} \sim N\left(\omega, \frac{\sigma^2}{S_{xx}}\right), \frac{\hat{\omega} - \omega}{\sqrt{\sigma^2/S_{xx}}} \sim N(0, 1)$

$\hat{b} = \bar{Y} - \hat{\omega} \bar{x} \sim N(b, \sigma^2/nS_{xx} \sum x_i^2), \varepsilon_i \sim N(0, \sigma^2)$

**假设检验**:  $H_0: \omega = 0$  vs  $H_1: \omega \neq 0, p = 2\Phi\left(|\hat{\omega}|/\sqrt{\sigma^2/S_{xx}}\right)$

P 小  $H_1$  真, 检验越合理。  $\sum (y_i - \bar{y})^2 = \sum (\hat{y}_i - \bar{y})^2 + \sum (y_i - \hat{y}_i)^2$

确定系数:  $r^2 = S_{yy}^2/(S_{xx}S_{yy})$ , 越接近 1 拟合效果越好

**多项式回归**:  $y = \omega_0 + \omega_1 x + \omega_2 x^2 + \dots + \omega_m x^m, y = Xw$

**多元回归**:  $y = \omega_0 + \omega_1 x_1 + \omega_2 x_2 + \dots + \omega_m x_m, y = Xw$

$y = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}, X = \begin{pmatrix} 1 & \cdots & x_{1m} \\ 1 & x_{21} & x_{2m} \\ & \ddots & \\ 1 & x_{n1} & x_{nm} \end{pmatrix}, W = \begin{pmatrix} \omega_0 \\ \vdots \\ \omega_n \end{pmatrix}, \min(y - Xw)^T (y - Xw)$   
 $\Rightarrow w = (X^T X)^{-1} X^T y$

**正则化**:  $\min(y - Xw)^T (y - Xw) + \lambda f(w)$

$\lambda f(w): \lambda \|w\|_1, \lambda \|w\|_2, \lambda \|w\|_0, \lambda_1 \|w\|_1 + \lambda_2 \|w\|_2$

$\hat{\omega}_j \leftarrow \hat{\omega}_j \max(0, (1 - n\lambda) \hat{\omega}_j), (1 - n\lambda)^{-1} \hat{\omega}_j, \hat{\omega}_j I(\hat{\omega}_j \geq \sqrt{n\lambda}), ?$

泛化误差:  $E(f: D) = \text{var}(x) + \text{bias}^2(x) + \varepsilon^2$

监督学习: Logistic 回归

**L 回归**:  $y = \pi(x) = \frac{1}{1 + \exp\{-(wx + b)\}}, \pi'(x) = w\pi(x)(1 - \pi(x))$

$P(Y = 1) = 1/(1 + \exp\{-(wx + b)\}) = \pi(x), P(Y = 0) = 1 - \pi(x)$

$\log \frac{P(Y = 1)}{1 - P(Y = 1)} = wx + b, e^w = \frac{\pi(x+1)/(1 - \pi(x+1))}{\pi(x)/(1 - \pi(x))}$

**对数似然**:  $L(w, b | x, y) = f(y | w, b, x) = \prod_{i=1}^n \pi^{y_i}(x_i)(1 - \pi(x_i))^{1 - y_i}$

$l(w, b | x, y) = \sum_{i=1}^n -H(p_i, q_i)$ , 需要  $\max \sum_{i=1}^n -H(p_i, q_i)$

**经验损失**:  $J(w, b) = \frac{1}{n} \sum_{i=1}^n H(p_i, q_i)$ , 需要  $\min \frac{1}{n} \sum_{i=1}^n H(p_i, q_i)$

其中  $H(p, q) = E_p(-\log q) = -y_i \log \pi(x_i) - (1 - y_i) \log(1 - \pi(x_i))$

梯度下降找最小:  $x^{new} \leftarrow x - \alpha \nabla f(x)$

$\frac{de}{db} = \frac{de}{d\pi} \frac{d\pi}{dz} \frac{dz}{db} = \pi - y, \frac{de}{dw} = (\pi - y)x$

$\frac{de}{d\pi} = -\frac{y}{\pi} + \frac{1 - y}{1 - \pi}, \frac{d\pi}{dz} = \frac{1}{1 + e^{-z}} \frac{e^{-z}}{1 + e^{-z}} = \pi(1 - \pi)$  | 从输出算梯度

二分类的评价

T/F: True / False ; P / N : Positive / Negative ; R : Rate  
TPR = TP / (TP + FN); FPR = FP / (TN + FP); TNR = TN / (TN + FP)  
FNR = FN / (TP + FN); 敏感Sensitivity = TPR; 1-Sensitivity = FNR  
特异Specificity = TNR; 1-Specificity = FPR; Fall-out = FP/(TP+FP)  
精度 Precision = TP / (TP + FP); 召回率 Recall = TP / (TP + FN);  
F1-score = 2TP / (2TP + FP + FN) = 2\*P\*R / (P+R) | P/R: 精度/召回  
Accuracy = (TP+TN) / (TP+TN+FN+TN);  
BER = 1/2(FPR+FNR); BCR = 1/2(TPR+TNR)

$MCC = (TP \cdot TN - FP \cdot FN) / \sqrt{(TP + FP)(FP + TN)(TN + FN)(FN + TP)}$

混淆矩阵	真实结果		ROC: 横(假阳性率)1- specifi, 纵(真阳性率)Sensitivity
	Positive	Negative	
预测结果	Claim Posi	Claim Nega	TP FN TP TN

**softmax 回归**:  $P(Y = k) = e^{w_k x + b_k} / \sum_{j=1}^J e^{w_j x + b_j} = \pi_k(x)$

$\max \sum_{i=1}^n \sum_{k=1}^J y_{ik} \log \pi_k(x_i)$

$\min -\frac{1}{n} \sum_{i=1}^n \sum_{k=1}^J y_{ik} \log \pi_k(x_i)$

$\frac{de}{db_i} = -\sum_{k=1}^J \frac{\partial e}{\partial \pi_k} \frac{\partial \pi_k}{\partial z_i} \frac{\partial z_i}{\partial b_i} = \pi_i - y_i, x$

$\frac{de}{dw_i} = (\pi_i - y_i)x, \frac{d\pi_k}{dz_i} = \begin{cases} e^{z_i}, k = i \\ 0, k \neq i \end{cases} \frac{\partial e}{\partial \pi_k} = -\frac{y_k}{\pi_k}, \frac{\partial z_i}{\partial b_i} = 1, \frac{\partial z_i}{\partial w_i} = x$

**一元变多元**:  $wx + b \leftarrow \sum_{j=1}^m w_j x_j, w_k x + b_k \leftarrow \sum_{j=1}^m w_{jk} x_j$

前馈神经网络: 输入单元—隐层单元—输出单元

**线性单元**:  $x = (x_1, x_2, \dots, x_m)^T, w = (w_1, w_2, \dots, w_m)^T$

$z = w^T x + b, \frac{da}{dw} = \frac{da}{dz} \frac{dz}{dw} = 1 \cdot 1, \frac{da}{dw} = \frac{da}{dz} \frac{dz}{dw} = 1 \cdot x^T$

$a = z$

**Logistic 单元**:  $z = w^T x + b, a = 1/(1 + e^{-z})$

$\frac{\partial a}{\partial b} = \frac{da}{dz} \frac{dz}{db} = a(1 - a), \frac{\partial a}{\partial w} = \frac{da}{dz} \frac{dz}{dw} = a(1 - a)x^T$

**Softmax**:  $w_i = (w_{i1}, \dots, w_{im})^T, W = (w_1, \dots, w_m), b = (b_1, \dots, b_m)^T$

$z = Wx + b, a_i = \frac{\exp(z_i)}{\sum_{k=1}^K \exp(z_k)}, a_i = \frac{e^{z_i}}{\sum_{k=1}^K e^{z_k}}, e = -y^T \log a$

$z_i = W_{[i]} x + b_i, a_i = \frac{\exp(z_i)}{\sum_{k=1}^K \exp(z_k)}$

$J_{ew} = \left( \frac{\partial e}{\partial a_i} \right)_{i \in I} \left( \frac{\partial a_i}{\partial z_i} \right)_{i \in I} \left( \frac{\partial z_i}{\partial w_{jk}} \right)_{j \in I^*(j_m)} = \left( \frac{\partial e}{\partial w_{jk}} \right)_{j \in I^*(j_m)}, J_{eb} = \left( \frac{\partial e}{\partial b_j} \right)_{j \in I}$



**双曲正切单元:**  $a = (\mathrm{e}^z - \mathrm{e}^{-z})/(\mathrm{e}^z + \mathrm{e}^{-z})$ ,  $da/db = 1 - a^2$   
**整流线性单元(ReLU):**  $a = \max(0, z)$ ,  $da/dz = 1, z > 0; 0, \text{other}$   
梯度消失问题略优。其他隐层单元:  $\text{softplus} a = \log(1 + \mathrm{e}^z)$   
**输入单元—隐层单元(一般 ReLU)—输出单元(按需选)**  
**网络结构设计:**可表示区域的数量是深度的指数函数(d 深度,每个隐层 k 单元 m 输入):  $O(k^m((k-m)^Y)^{m(d-1)})$   
**随机梯度下降:**一次用一个样例更新梯度(SGD)

**动量梯度下降**位移导是速度  $v(t) = \frac{\partial}{\partial t} d(t)$ , 速度导是受力  $f(t) = \frac{\partial}{\partial t} v(t)$ , 将位移类比参数  $\Delta \theta \propto v$ , 受力类比负梯度  $\Delta v \propto -\nabla_\theta$ 。参数更新公式:  $v \leftarrow \alpha v - \varepsilon \nabla_\theta$ ,  $\theta \leftarrow \theta + v$   
Nesterov 动量:  $\tilde{\theta} \leftarrow \theta + \alpha v, v \leftarrow \alpha v - \varepsilon \nabla_{\tilde{\theta}}, \theta \leftarrow \theta + v$

**参数初始化策略**  
破坏对称性:与同一个输入相连的具有相同激活函数的隐层单元参数不同; 随机初始化:权重随机产生,偏置设为零  
**学习速率调整方法:**学习速率反比于梯度累计平方和的根  
线性衰减:  $\alpha_k = \begin{cases} \lambda \alpha_r + (1-\lambda) \alpha_0, k \leq \tau \\ \alpha_r, k > \tau \end{cases}$  //自适应衰减:

AdaGrad (Duchi et al., 2011) Adam (Kingma and Ba, 20)  $\mathbf{r} \leftarrow \mathbf{r} + \mathbf{g} \odot \mathbf{g}$   $\mathbf{s} \leftarrow \rho_1 \mathbf{s} + (1 - \rho_1) \mathbf{g}$   $\mathbf{r} \leftarrow \rho_2 \mathbf{r} + (1 - \rho_2) \mathbf{g} \odot \mathbf{g}$   $\hat{\mathbf{s}} \leftarrow \frac{\mathbf{s}}{1 - \rho_1^k}$   $\hat{\mathbf{r}} \leftarrow \frac{\mathbf{r}}{1 - \rho_2^k}$   $\mathbf{r} \leftarrow \rho \mathbf{r} + (1 - \rho) \mathbf{g} \odot \mathbf{g}$   $\mathbf{r} \leftarrow \mathbf{r} - \frac{\epsilon}{\delta + \sqrt{\mathbf{r}}} \odot \mathbf{g}$   $\mathbf{r} \leftarrow \mathbf{r} - \frac{\epsilon}{\delta + \sqrt{\mathbf{r}}} \odot \hat{\mathbf{s}}$

**正则化:**增加数据/提前终止/修改目标函数加入惩罚项  
简化网络结构:随机扔掉一些节点/连接  
**批次标准化:**SGD 过程中对隐层输出标准化,可以用较大学习率/提升训练速度/收敛快/性能好(类似扔节点的正则化方法)/初始参数要求低  $\mu_{\mathbf{b}} \leftarrow 1/m \sum \mathbf{x}_i, \sigma_{\mathbf{b}}^2 \leftarrow 1/m \sum (\mathbf{x}_i - \mu_{\mathbf{b}})^2$   
 $\hat{\mathbf{x}}_i \leftarrow (\mathbf{x}_i - \mu_{\mathbf{b}}) / \sqrt{\sigma_{\mathbf{b}}^2 + \epsilon}$   
 $\mathbf{y}_i \leftarrow \gamma \hat{\mathbf{x}}_i + \beta = \text{BN}_{\gamma, \beta}(\mathbf{x}_i)$

**卷积神经网络**

**卷积:**填充:允许卷积核超出边界(Samepadding)如边缘补 0。  
**稀疏连接:**可以用全连接的前馈网络实现,不参与卷积的点权重为 0。节点 N, 卷积核 m\*m, 连接  $O(m^2 N)$   
**参数共享:**在不同位置卷积时像素点一样则结果一样(等表示), 局部特征为制不重要,  $O(m^2)$ 。  
非共享卷积核/平铺卷积核:不共享参数/不完全共享参数  
1\*1 卷积核可以降低/多个卷积核升维/减少计算量  
**池化:**用某一位置相邻输出的统计特征代替该位置的输出。池化函数:最大池化/平均池化/随机池化  
步长大于 1 的池化能够降低输入规模。  
**卷积神经网络典型结构:**卷积层、池化层叠起来,再由全连接网络完成相关学习。卷积功能:特征提取—端到端学习。  
**训练过程:**前向/后向,关键是池化和卷积单元的梯度计算。数据的扩增:原图抽取小图、原图进行几何变换等。  
图卷积模型:  $\mathbf{x}_i^{(com)} \leftarrow \mathbf{w}_i \mathbf{x}_i + \sum_{u \in \mathbf{u}_i} \mathbf{w}_u \mathbf{x}_u$ ,  $\mathbf{u}$  是邻居  
**非监督学习:**聚类/降维/生成  
聚类(K-means):初值:随机选择中心点  $\mu = \{\mu_1, \dots, \mu_2\}$ , 指派降维(主成分分析)  $\mathbf{A} = \mathbf{XW}, \tilde{\mathbf{X}} = \mathbf{A}\mathbf{W}^T$   
 $\max \mathbf{w}^T \mathbf{X}^T \mathbf{X} \mathbf{w}, \text{s.t. } \mathbf{w}^T \mathbf{w} = 1, \mathbf{X}^T \mathbf{X} \mathbf{w} = \lambda \mathbf{w}, \max \lambda$   
降维(自编码器):encoder-code-decoder,编码作为新特征生成(VAE:GAN):学习编码分布,而非编码本身。

**强化学习**

**马尔可夫过程:二元组**  $(S, P)$  状态空间  $S = \{s_1, \dots, s_n\}$   
状态转移矩阵  $P = (p_{ss'})_{n \times n}, p_{ss'} = P(S_{t+1} = s' | S_t = s)$   
**马尔可夫回报过程:四元组**  $(S, P, r, \gamma)$   
状态转移  $S_t \rightarrow S_{t+1}$  产生回报  $R_{t+1}$ 。折现因子  $\gamma \in [0, 1]$ ;期望状态回报  $\mathbf{r} = \{r_1, r_2, \dots, r_n\}, \mathbf{r}_s = E[R_{t+1} | S_t = s] = \sum_{r \in R} rp(r | S_t = s)$   
累计回报:  $G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1}$   
状态价值函数:  $v(s) = E[G_t | S_t = s] = r_s + \gamma \sum_{s' \in S} p_{ss'} v(s')$   
贝尔曼期望方程:  $\mathbf{v} = \mathbf{r} + \gamma \mathbf{P} \mathbf{v}, \mathbf{v} = (\mathbf{I} - \gamma \mathbf{P})^{-1} \mathbf{r}$   
**马尔可夫决策过程:五元组**  $(S, A, P, R, \gamma)$   
行动  $A_t$  导致状态转移  $S_t \rightarrow S_{t+1}$  产生回报  $R_{t+1}$  行动空间:  $A = \{a_1, a_2, \dots, a_m\}$ ; 状态转移矩阵:  $P = (p_{ss'}^a)_{n \times n \times m}$  其中  $p_{ss'}^a = P(S_{t+1} = s' | S_t = s, A_t = a) = \sum_{r \in R} p(s', r | s, a)$ ; 行动期望回报  $\mathbf{R} = (r_s^a)_{n \times m}, r_s^a = E[R_{t+1} | S_t = s, A_t = a] = \sum_{r \in R} r \sum_{s'} p(s', r | s, a)$   
**策略:**  $\pi(a | s) = P(A_t = a | S_t = s)$ ,  $s$  下选策略  $a$  的概率。  
 $p^{\pi}(S_{t+1} = s' | S_t = s) = \sum_{a \in A} \pi(a | s) p_{ss'}^a, r_s^{\pi} = \sum_{a \in A} \pi(a | s) r_s^a$   
**状态价值:**  $v_{\pi}(s) = E[G_t | S_t = s] = \sum_{a \in A} \pi(a | s) q_{\pi}(s, a)$   
**行动价值:**由后续状态价值的加权计算。  
 $q_{\pi}(s, a) = E[G_t | S_t = s, A_t = a] = r_s^a + \gamma \sum_{s' \in S} p_{ss'}^a v_{\pi}(s')$

**贝..期望方程:**  $v_{\pi}(s) = \sum_{a \in A} \pi(a | s) (r_s^a + \gamma \sum_{s' \in S} p_{ss'}^a v_{\pi}(s'))$   
 $q_{\pi}(s, a) = r_s^a + \gamma \sum_{s' \in S} p_{ss'}^a \sum_{a' \in A} \pi(a' | s') q_{\pi}(s', a')$

矩阵形式:  $\mathbf{v} = \mathbf{r}^{\pi} + \gamma \mathbf{P}^{\pi} \mathbf{v}, \mathbf{v} = (\mathbf{I} - \gamma \mathbf{P}^{\pi})^{-1} \mathbf{r}^{\pi}$   
**动态规划**—策略评价(状态价值计算)、策略改进  
 $\mathbf{v}^{(k+1)} = \mathbf{r}^{\pi} + \gamma \mathbf{P}^{\pi} \mathbf{v}^{(k)}, \mathbf{v}_{k+1}(s) = r_s^{\pi} + \gamma \sum_{s' \in S} p_{ss'}^{\pi} v_k(s')$



最优状态价值:  $v_{*}(s) = \max_{\pi} v_{\pi}(s) = v_{\pi_{*}}(s)$   
最优行动价值:  $q_{*}(s, a) = \max_{\pi} q_{\pi}(s, a) = q_{\pi_{*}}(s, a)$   
最优  $a$  价值是同时刻最优  $q$  价值  $v_{*}(s) = \max_{a \in A} q_{*}(s, a)$

最优策略(**贪心策略**):  $\pi_{*}(a | s) = 1, \text{ if } a = \arg \max_{a'} q_{*}(s, a)$   
策略迭代:已知策略  $\pi$ , 用动态规划计算出各个行动下的状态价值  $\mathbf{v}$  (直至收敛,或者算一步改进一次),在某状态可行的所有策略中选择使得状态价值最大的那个(贪心策略),然后重复以上过程,得到一列状态、策略。 $\mathbf{v}_{k+1}(s) = \max_{a \in A} (r_s^{\pi} + \gamma \sum_{s' \in S} p_{ss'}^{\pi} v_k(s'))$   
同步迭代:算完所有  $s$  更新一次策略。(不用算  $\mathbf{v}$  至收敛)  
异步迭代:算完一个  $s$  就更新一次策略。

**蒙特卡洛**—无  $P$  矩阵时状态价值预测、策略改进  
已知观测片段,对某个状态  $S$ , 以其出现作为开始计算出这些幕各自的  $G_i$ , 对这些  $G_i$  取平均值来估计  $v(s)$ 。 $V(S_t) = 1/n \sum G_i$ , 其中  $G_i = R_{t+1} + \gamma R_{t+2} + \dots + \gamma^{T-i} R_{T+1}$   
首次访问/每次访问:作为起始的  $s$  是否第一次出现。  
增量式蒙特卡洛:  $V(S_t) \leftarrow V(S_t) + 1/k (G_t - V(S_t)), k \leftarrow k + 1$   
定步长蒙特卡洛:  $V(S_t) \leftarrow V(S_t) + \alpha (G_t - V(S_t))$   
无模型时预测行动价值,  $q_{\pi}(s, a) \approx 1/n \sum G_i$   
增量式:  $Q(S_t, A_t) \leftarrow Q(S_t, A_t) + 1/k (G_t - Q(S_t, A_t)), k \leftarrow k + 1$   
定步长:  $Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha (G_t - Q(S_t, A_t))$   
策略改进:  $\pi'(S_t) = \arg \max_{a \in A} Q(S_t, a)$

**贪心改进:**  $\pi_{*}(a | s) = \begin{cases} 1 - \varepsilon + \varepsilon / m, \text{ if } a = \arg \max_{a'} q_{*}(s, a) \\ \varepsilon / m, \text{ otherwise} \end{cases}$   
**时序差分**—从部分序列学习  
递推状态价值:  $V(S_t) \leftarrow V(S_t) + \alpha (R_{t+1} + \gamma V(S_{t+1}) - V(S_t))$   
蒙从完整序列学习,适用带终止的决策过程/离线学习(必须获得完整片段来估计累计汇报)/非马更有效; 时序从部分序列学习,可用于无终止状态的决策过程/在线学习,只需获取下一状态的及时回报/马环境更有效。

**非常慢**  
一行: 本层的一个神经元  
一列: 前层的一个神经元



序列产生: **Behavior policy** ↓ **Target policy**  
**行为策略** **目标策略**  
在线策略:目标策略和行为策略相同(SARSA)  
离线策略:不同(Q-learning, E-SARSA)  
当前状态  $S_t$ , 根据行为策略选择  $A_t$  获得回报  $R_{t+1}$ 、下一状态  $S_{t+1}$ , 根据目标策略从  $S_{t+1}$  产生  $A_{t+1}$ , 计算  $Q(S_{t+1}, A_{t+1})$ , 迭代更新  $Q(S_t, A_t)$ 。不断循环以更新  $Q$  表。

**算法 SARSA:**行为策略和目标策略都是  $\varepsilon$ -greedy  
 $Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha (R_{t+1} + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t))$   
 $\pi'(S_{t+1}) = \arg \max_{a \in A} Q(S_{t+1}, a), Q(S_{t+1}, A_{t+1}) = \max_{a \in A} Q(S_{t+1}, a)$   
**算法 Q-learning:**行为策略  $\varepsilon$ -greedy 目标策略 greedy  
 $Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha (R_{t+1} + \gamma \max_{a \in A} Q(S_{t+1}, a) - Q(S_t, A_t))$   
**算法 E-SARSA:**行为策略  $\varepsilon$ -greedy 目标策略行动期望  
 $Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha (R_{t+1} + \gamma \sum_{a \in A} \pi(a | S_{t+1}) Q(S_{t+1}, a) - Q(S_t, A_t))$

**增量式价值近似**  
**状态价值近似:**特征提取  $\mathbf{x}(s) = (x_1(s), x_2(s), \dots, x_m(s))^T$ , 函数族  $\hat{v}(s | \mathbf{x}, \mathbf{w}) = \mathbf{w}^T \mathbf{x}$  (线性函数),  
优化准则  $\min_{\mathbf{w}} \sum_{i=1}^n (v_{\pi}(s_i) - \hat{v}(s_i | \mathbf{x}, \mathbf{w}))^2$ ,  
优化方法 SGD:  $\mathbf{w}^{(new)} \leftarrow \mathbf{w} + \alpha (v_{\pi}(s) - \hat{v}(s | \mathbf{x}, \mathbf{w})) \mathbf{x}$   
**行动价值近似:**特征提取  $\mathbf{x}(s, a) = (x_1(s, a), \dots, x_m(s, a))^T$ , 函数族  $\hat{q}(s, a | \mathbf{x}, \mathbf{w}) = \mathbf{w}^T \mathbf{x}$  (线性函数),  
优化准则  $\min_{\mathbf{w}} \sum_{i=1}^n (q_{\pi}(s_i, a_i) - \hat{q}(s_i, a_i | \mathbf{x}, \mathbf{w}))^2$ ,  
优化方法 SGD:  $\mathbf{w}^{(new)} \leftarrow \mathbf{w} + \alpha (q_{\pi}(s, a) - \hat{q}(s, a | \mathbf{x}, \mathbf{w})) \mathbf{x}$

**批量式价值近似(经验回放)**  
**经验回放的 SGD 方法:**  $\mathbf{w}^{(new)} \leftarrow \mathbf{w} + \alpha (v_{\pi}(s) - \hat{v}(s | \mathbf{x}, \mathbf{w})) \mathbf{x}$   
交替进行采样和梯度下降至收敛  $\min \sum (v_{\pi}(s) - \hat{v}(s | \mathbf{x}, \mathbf{w}))^2$   
**状态价值的蒙特卡洛经验回放:**  $v_{\pi}(s) \approx G_t$   
积累经验:  $D = \{(s_1, G_t(s_1)), \dots, (s_n, G_t(s_n))\}$   
从经验采样:  $(s, G_t(s)) \sim D$ , 计算系数:  $\mathbf{w} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{g}$   
**状态价值的时序差分经验回放:**  $v_{\pi}(s) \approx R_{t+1} + \hat{v}(S_{t+1} | \mathbf{x}, \mathbf{w})$   
 $D = \{(s_1, r_1', s_1'), \dots, (s_n, r_n', s_n')\}, (s_i, r_i', s_i') \sim D, \mathbf{w} = (\mathbf{X}^T (\mathbf{X} - \gamma \mathbf{X}))^{-1} \mathbf{X}^T \mathbf{r}$   
**行动价值的时序差分经验回放:**  
 $D = \{(s_1, a_1, r_1', s_1', a_1'), \dots, (s_n, a_n, r_n', s_n', a_n')\}, (s_i, a_i, r_i', s_i', a_i') \sim D$

**深度强化学习**用神经网络做价值近似, Deep Q-Network

$b_i^{[k]} w_{ij}^{[k]} \rightarrow$  第  $k$  个隐层  
 $\rightarrow$  第  $i$  个神经元 (第  $k$  层)  
 $\rightarrow$  第  $j$  个神经元 (前一层)

